

# Détection d'intrusions par l'analyse Big Data des fichiers logs

Réalisé par : ALLAL Yahia , AIT ICHOU Mustapha , AMMOURI Yassire

Faculté des Sciences de Rabat

12 Juillet 2024



# Plan

- 1 Problématique
- 2 Définition des Fichiers de Logs et leurs Types
- 3 DataSet
- 4 Les modèles de machine learning choisis
- 5 Les outils & Implémentation
- 6 Démonstration
- 7 Conclusion

# Problématique

# Problématique



- 1 Les systèmes informatiques sont essentiels.
- 2 La sécurité des systèmes est très importante.(Alors, comment peut-on protéger... ?)
- 3 Les anciennes méthodes ne sont pas efficaces.
- 4 En utilisant les outils de big data pour résoudre ce problème.

## Définition des Fichiers de Logs et leurs Types

# Définition des Fichiers de Logs



Figure: Définition des Fichiers de Logs et leurs Types

Les fichiers de logs sont des enregistrements chronologiques des événements ou des transactions générés par les systèmes informatiques.

# Types des Fichiers de Logs



Figure: Les Types de Fichiers de Logs

- **Log web** : Sont des événements web (les requêtes HTTP, les adresses IP des visiteurs, et les erreurs serveur).
- **Log de réseau** : Sont les activités et les erreurs liées aux services de réseau (les connexions entrantes et sortantes, les transferts de données).
- **Log système** : Sont des événements généraux du système (les démarrages et arrêts, les mises à jour du système).

# DataSet



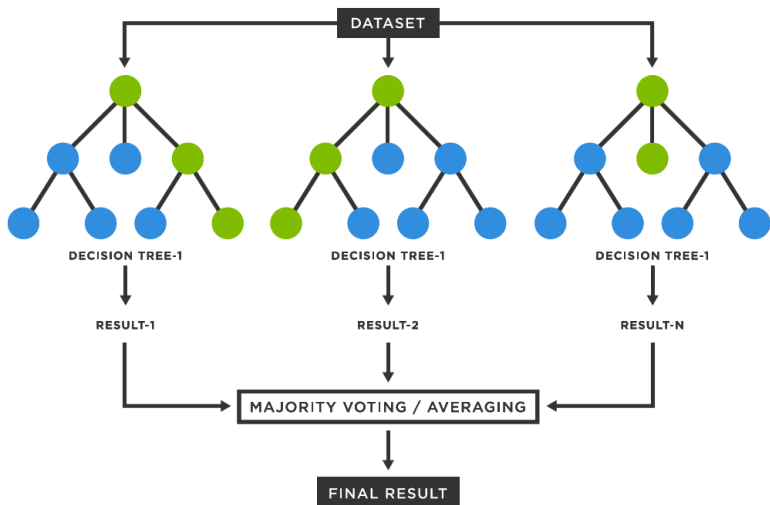
# Data set : KDDCup99


## KDDCup99

- **Nombre d'Instances** : Environ 4,9 millions d'instances de connexions réseau.
- **Nombre de features** : 42 caractéristiques
- **Types d'Attaques** : 22 types d'attaques répartis en quatre catégories principales :
  - **Denial of Service (DoS)** : Déné de service
  - **Remote to Local (R2L)** : À distance vers local
  - **User to Root (U2R)** : Utilisateur vers superutilisateur
  - **Probing or port scanning** : Exploration ou balayage de port

## Les modèles de machine learning choisis

# Random Forest





Testing Set:


	precision	recall	f1-score	support
0	1.00	1.00	1.00	13386
1	1.00	1.00	1.00	11809
accuracy			1.00	25195
macro avg	1.00	1.00	1.00	25195
weighted avg	1.00	1.00	1.00	25195

Confusion Matrix:

```
[[13379  7]
 [ 25 11784]]
```

Accuracy: 0.9987299067275253

# Artificial Neural Network (ANN)



```



model = tf.keras.Sequential([
    tf.keras.layers.Dense(units=64, activation='relu', input_shape=(x_train.shape[1:]),
                           kernel_regularizer=regularizers.L1L2(l1=1e-5, l2=1e-4),
                           bias_regularizer=regularizers.L2(1e-4),
                           activity_regularizer=regularizers.L2(1e-5)),
    tf.keras.layers.Dropout(0.4),
    tf.keras.layers.Dense(units=128, activation='relu',
                           kernel_regularizer=regularizers.L1L2(l1=1e-5, l2=1e-4),
                           bias_regularizer=regularizers.L2(1e-4),
                           activity_regularizer=regularizers.L2(1e-5)),
    tf.keras.layers.Dropout(0.4),
    tf.keras.layers.Dense(units=512, activation='relu',
                           kernel_regularizer=regularizers.L1L2(l1=1e-5, l2=1e-4),
                           bias_regularizer=regularizers.L2(1e-4),
                           activity_regularizer=regularizers.L2(1e-5)),
    tf.keras.layers.Dropout(0.4),
    tf.keras.layers.Dense(units=128, activation='relu',
                           kernel_regularizer=regularizers.L1L2(l1=1e-5, l2=1e-4),
                           bias_regularizer=regularizers.L2(1e-4),
                           activity_regularizer=regularizers.L2(1e-5)),
    tf.keras.layers.Dropout(0.4),
    tf.keras.layers.Dense(units=1, activation='sigmoid'),
])

```

```

4/4 [=====] - 0s 15ms/step - loss: 0.1675 - accuracy: 0.9714 - val_loss: 0.1304 - val_accuracy: 0.9778
Epoch 29/30
4/4 [=====] - 0s 18ms/step - loss: 0.1579 - accuracy: 0.9714 - val_loss: 0.1180 - val_accuracy: 1.0000
Epoch 30/30
4/4 [=====] - 0s 14ms/step - loss: 0.1483 - accuracy: 0.9619 - val_loss: 0.1051 - val_accuracy: 1.0000
Model: "sequential_8"

```



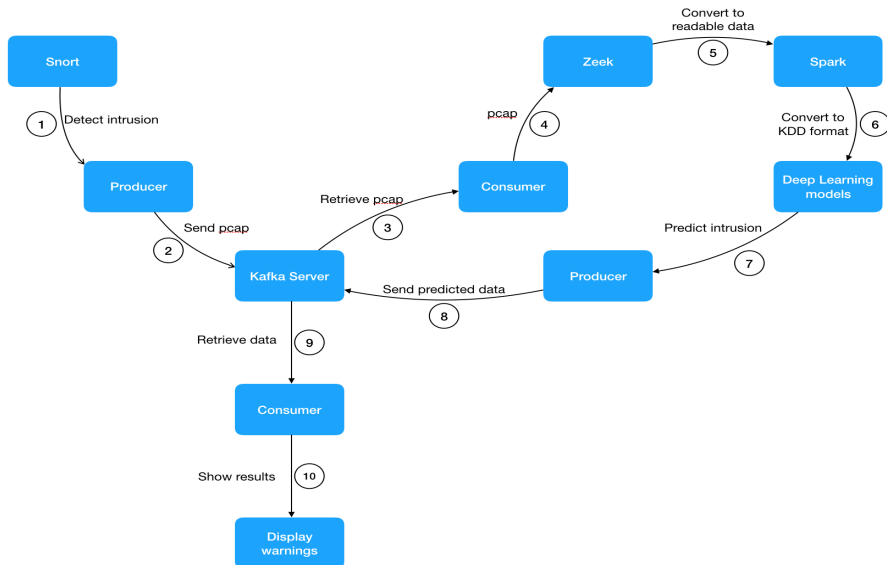
## Les outils & Implémentation




# Les outils




# Implmentation



# Comment fonctionne Kafka



## Kafka Topic Partitions Layout



# Démonstration

## Conclusion

# Conclusion

La détection d'intrusions par l'analyse Big Data des fichiers logs présente plusieurs défis :

- ➊ **Attaques zero-day** : Difficiles à détecter car elles exploitent des vulnérabilités inconnues.
- ➋ **Complexité des environnements réseau** : Adaptation aux réseaux modernes complexes et distribués.
- ➌ **Évolution des techniques d'attaque** : Les systèmes doivent s'adapter rapidement aux nouvelles menaces.

# Merci pour votre attention !

